

Bagian Pemodelan

Sistem Parkir Cerdas Berbasis Computer Vision

1. Arsitektur Model

1.1 Gambaran Umum Pipeline

Sistem parkir cerdas yang dikembangkan menggunakan arsitektur pipeline multi-tahap yang memproses citra masukan dari kamera gerbang parkir hingga menghasilkan keputusan akses:

```
Citra Input → Deteksi Plat (YOLO) → OCR Plat Nomor → Ekstraksi Fitur Visual  
→ Skoring & Keputusan
```

1.2 Modul Deteksi (YOLO)

Modul pertama menggunakan model berbasis YOLO (*You Only Look Once*) untuk mendeteksi keberadaan plat nomor kendaraan pada citra. YOLO dipilih berdasarkan pertimbangan teknis berikut:

- **Efisiensi inferensi:** YOLO merupakan detektor *single-stage* yang melakukan prediksi *bounding box* dan klasifikasi dalam satu *forward pass*, berbeda dengan detektor *two-stage* seperti Faster R-CNN yang memerlukan *region proposal* terpisah.
- **Kesesuaian untuk *real-time*:** Latensi inferensi YOLO pada resolusi standar (640×640) berada pada orde milidetik, memenuhi kebutuhan respons waktu-nyata di gerbang parkir.
- **Trade-off akurasi vs. kecepatan:** Model YOLO varian kecil (misalnya YOLOv8n atau YOLOv8s) mengorbankan sebagian akurasi deteksi pada objek berukuran kecil demi kecepatan inferensi yang lebih tinggi. Pada konteks deteksi plat nomor — di mana objek target relatif kecil dalam *frame* — pemilihan varian model menjadi pertimbangan kritis.

Model menerima citra RGB sebagai input dan menghasilkan *bounding box* beserta *confidence score* untuk setiap plat nomor yang terdeteksi.

1.3 Modul OCR

Setelah *bounding box* plat nomor diperoleh, area plat di-*crop* dan diteruskan ke modul OCR (*Optical Character Recognition*) untuk mengekstraksi teks karakter pada plat. Modul ini berfungsi sebagai penghubung antara deteksi visual dan verifikasi identitas kendaraan terhadap basis data. Akurasi OCR sangat dipengaruhi oleh kualitas hasil *cropping*, resolusi area plat, serta kondisi pencahayaan.

1.4 Modul Ekstraksi Fitur Visual

Modul ini mengekstraksi fitur tambahan dari citra kendaraan secara keseluruhan:

- **Warna kendaraan** — klasifikasi kasar (*coarse classification*)
- **Tipe kendaraan** — klasifikasi kasar (mobil, motor, truk, dsb.)

Fitur-fitur ini berfungsi sebagai sinyal pendukung dalam mekanisme verifikasi multi-faktor.

1.5 Modul Skoring dan Keputusan

Modul akhir mengintegrasikan seluruh sinyal dari modul sebelumnya melalui sistem *confidence scoring* berbobot untuk menghasilkan keputusan akses gerbang. Detail mekanisme ini disajikan pada Subbagian 5.

2. Persiapan Data

2.1 Pembagian Dataset

Dataset yang digunakan adalah dataset plat nomor kendaraan Indonesia dengan pembagian sebagai berikut:

Split	Jumlah Citra	Proporsi
Training	800	80%
Validation	100	10%
Test	100	10%

Pembagian 80/10/10 mengikuti konvensi umum dalam *deep learning* untuk dataset berukuran terbatas. Set validasi digunakan untuk pemantauan *overfitting* selama pelatihan, sedangkan set tes disisihkan untuk evaluasi akhir yang objektif.

2.2 Format Anotasi

Anotasi menggunakan format standar YOLO, di mana setiap citra memiliki file `.txt` berpasangan dengan format:

```
<class_id> <x_center> <y_center> <width> <height>
```

Seluruh koordinat dinormalisasi terhadap dimensi citra (rentang [0, 1]). Dataset ini menggunakan satu kelas (`class_id = 0`) yang merepresentasikan plat nomor kendaraan. Beberapa citra memiliki lebih dari satu anotasi, mengindikasikan keberadaan multiple plat nomor dalam satu *frame*.

Contoh anotasi aktual dari dataset:

```
0 0.590774 0.714782 0.104167 0.034722
```

Baris di atas menunjukkan plat nomor dengan pusat pada (59.08%, 71.48%) dari dimensi citra, dengan lebar 10.42% dan tinggi 3.47% — konsisten dengan proporsi geometris plat nomor standar Indonesia yang bersifat horizontal dan berukuran relatif kecil terhadap keseluruhan citra.

2.3 Preprocessing

Tahapan *preprocessing* standar yang diterapkan:

1. **Resizing**: Citra di-*resize* ke resolusi tetap (umumnya 640×640 piksel untuk YOLO) dengan *letterboxing*.
2. **Normalisasi**: Nilai piksel dinormalisasi ke rentang [0, 1] melalui pembagian dengan 255.
3. **Konversi format warna**: Konversi dari BGR (OpenCV) ke RGB sesuai kebutuhan model.

2.4 Augmentasi Data

Mengingat ukuran dataset yang terbatas (800 citra pelatihan), teknik augmentasi yang lazim diterapkan:

- *Random horizontal flip*
- Variasi *brightness*, *contrast*, dan *saturation*
- *Mosaic augmentation* (penggabungan 4 citra — teknik bawaan YOLO)
- *Random scaling* dan *translation*

Catatan: Teknik augmentasi spesifik yang diterapkan akan diintegrasikan setelah hasil pelatihan tersedia.

3. Strategi Pelatihan

3.1 Pendekatan Transfer Learning

Pelatihan dilakukan menggunakan *transfer learning*. Model YOLO yang telah dilatih pada dataset berskala besar (misalnya COCO, ~330.000 citra, 80 kelas) digunakan sebagai *pretrained backbone*. *Weight* awal dari *backbone* dipertahankan, sementara *head* deteksi di-*fine-tune* pada dataset plat nomor Indonesia.

Justifikasi:

1. **Keterbatasan data**: Dengan 800 citra, pelatihan *from scratch* akan menghasilkan *overfitting* parah karena jumlah parameter model jauh melebihi jumlah sampel.
2. **Pemanfaatan representasi visual umum**: *Pretrained backbone* telah mempelajari fitur visual fundamental yang bersifat *domain-agnostic*.
3. **Konvergensi lebih cepat**: Model mencapai performa baik dalam epoch yang lebih sedikit.

3.2 Konfigurasi Pelatihan

Pelatihan dilaksanakan pada lingkungan Kaggle (GPU NVIDIA Tesla P100 atau T4):

Parameter	Nilai Umum
Epoch	50–100
Batch size	16
Image size	640×640
Optimizer	SGD atau AdamW
Learning rate	0.01 (awal), <i>cosine decay</i>

Catatan: Hiperparameter aktual akan diperbarui setelah pelatihan selesai.

3.3 Risiko Overfitting

Strategi mitigasi:

- **Early stopping:** Pelatihan dihentikan saat metrik validasi stagnan.
- **Augmentasi data:** Memperluas variasi data secara artifisial.
- **Regularisasi implisit:** *Pretrained weights* membatasi model agar tidak menyimpang terlalu jauh.
- **Pemantauan *loss* validasi:** Divergensi *training loss* vs. *validation loss* dipantau sebagai indikator.

4. Peningkatan Fitur (Verifikasi Multi-Sinyal)

4.1 Keterbatasan Deteksi Plat Tunggal

Mengandalkan plat nomor sebagai satu-satunya mekanisme identifikasi memiliki keterbatasan:

- Plat nomor dapat tertutup sebagian (*occlusion*).
- Pencahayaan buruk menurunkan akurasi OCR secara drastis.
- Plat nomor palsu tidak dapat dideteksi hanya dari pengenalan karakter.

4.2 Fitur Pendukung Tambahan

a. Warna Kendaraan (Klasifikasi Kasar)

Klasifikasi warna (hitam, putih, merah, biru, silver) berdasarkan analisis histogram warna atau model klasifikasi ringan. Berfungsi sebagai sinyal verifikasi silang terhadap data terdaftar.

b. Tipe Kendaraan (Klasifikasi Kasar)

Klasifikasi tipe (mobil, motor, truk, bus) menggunakan fitur visual keseluruhan kendaraan. Konsistensi dengan data registrasi menambah *confidence* identifikasi.

4.3 Peran sebagai Sinyal Pendukung

Kedua fitur diposisikan sebagai **sinyal pendukung**, bukan primer:

1. Klasifikasi kasar memiliki akurasi lebih rendah dibandingkan pengenalan plat.
2. Warna dan tipe bersifat non-unik.
3. Fungsi utamanya: **menurunkan *false positive rate*** saat OCR ambigu.

5. Mekanisme Keputusan

5.1 Sistem Confidence Scoring

Keputusan akses gerbang ditentukan melalui *confidence scoring* berbobot:

$$S = (C_{\text{plat}} \times w_1) + (C_{\text{warna}} \times w_2) + (C_{\text{tipe}} \times w_3)$$

di mana:

- C_{plat} = skor kepercayaan pengenalan plat nomor (0–1)
- C_{warna} = skor kesesuaian warna kendaraan (0–1)
- C_{tipe} = skor kesesuaian tipe kendaraan (0–1)
- $w_1 + w_2 + w_3 = 1$

Distribusi bobot berdasarkan reliabilitas sinyal:

Sinyal	Bobot (w)	Justifikasi
Plat nomor	0.70	Identifikator unik paling reliabel
Warna	0.15	Sinyal pendukung, non-unik
Tipe	0.15	Sinyal pendukung, non-unik

Nilai bobot bersifat konfigurabel dan dapat dioptimasi melalui eksperimen empiris.

5.2 Keputusan Berbasis Threshold

Rentang Skor	Keputusan	Tindakan Sistem
$S \geq 0.85$	High confidence	Gerbang terbuka otomatis
$0.60 \leq S < 0.85$	Medium confidence	Gerbang terbuka dengan pencatatan log untuk review
$S < 0.60$	Low confidence	Mekanisme <i>fallback</i> (verifikasi manual/petugas)

5.3 Penekanan pada Robustness

Desain mengutamakan **robustness** di atas akurasi sempurna:

- Ambang *medium confidence* memungkinkan akses meski identifikasi tidak sempurna, menghindari *false rejection* berlebihan.
- Pencatatan log pada keputusan *medium* untuk audit dan peningkatan iteratif.
- Mekanisme *fallback* menjamin kontinuitas layanan pada kondisi kegagalan.

6. Pendekatan Evaluasi

6.1 Penggunaan Set Validasi dan Tes

1. **Validasi (100 citra)**: Pemantauan performa dan pemilihan *checkpoint* terbaik selama pelatihan.
2. **Tes (100 citra)**: Evaluasi akhir objektif, tidak digunakan selama pelatihan.

6.2 Metrik Evaluasi

Metrik	Definisi
mAP@0.5	<i>Mean Average Precision</i> pada IoU threshold 0.5
mAP@0.5:0.95	mAP rata-rata pada rentang IoU 0.5–0.95 (metrik lebih ketat)

Metrik	Definisi
Precision	Proporsi deteksi positif yang benar terhadap seluruh deteksi positif
Recall	Proporsi objek sebenarnya yang berhasil terdeteksi

6.3 Kebutuhan Data Tes Berlabel

Data tes dengan anotasi *ground truth* merupakan kebutuhan mutlak untuk evaluasi objektif. Dataset yang digunakan telah menyediakan anotasi format YOLO untuk seluruh split, sehingga evaluasi kuantitatif dapat dilaksanakan secara penuh.

7. Keterbatasan

1. **Ukuran dataset terbatas:** 800 citra pelatihan belum sepenuhnya merepresentasikan variasi plat nomor Indonesia (beragam format berdasarkan wilayah, jenis kendaraan, tahun pembuatan).
2. **Sensitivitas lingkungan:** Performa dipengaruhi oleh pencahayaan (malam, *glare*, *backlight*), oklusi parsial, dan sudut kamera tidak ideal.
3. **Ketidakkuratan OCR:** Karakter dengan kemiripan visual tinggi ("D"/"0", "I"/"1") serta kondisi plat aus menurunkan akurasi pengenalan.
4. **Kendala komputasi *real-time*:** Deployment pada perangkat *edge* (Raspberry Pi) memerlukan optimisasi tambahan yang berpotensi menurunkan akurasi.

8. Pengembangan ke Depan

1. **Ekspansi dataset:** Pengumpulan data plat nomor Indonesia yang lebih beragam. Target minimal 5.000–10.000 citra.
2. **Fine-tuning model:** Eksplorasi arsitektur YOLO terbaru (YOLOv8, YOLOv9, YOLOv11) serta model OCR yang di-*fine-tune* untuk karakter plat Indonesia.
3. **Optimisasi *edge deployment*:** Kuantisasi *post-training* (INT8), *knowledge distillation*, konversi ke format efisien (ONNX, TensorRT, TFLite). Target latensi di bawah 200ms per *frame* pada Raspberry Pi.
4. **Peningkatan fusi multi-sinyal:** Eksplorasi *learned fusion weights*, pendekatan *Bayesian*, dan adaptasi bobot dinamis berdasarkan kualitas citra.

Catatan akhir: Seluruh penjelasan didasarkan pada desain sistem dan data yang tersedia. Hasil eksperimental (metrik mAP, precision, recall, serta hiperparameter aktual) akan diintegrasikan setelah pelatihan dan evaluasi selesai.